



УКРАЇНА UKRAINE
ПАСПОРТ ГРОМАДЯНИНА УКРАЇНИ PASSPORT OF THE CITIZEN OF UKRAINE



Прізвище/ Surname
ПЕРЕДЕРЕЙ
PEREDEREI

Ім'я/ Name
БОГДАН
BOHDAN

По батькові/ *Patronymic*
ОЛЕКСАНДРОВИЧ

Статы/ Sex
Ч/М

Дата народження/ Date of birth
23 11 2003

Дійсний до/ Date of expiry
04 01 2032

Громадянство/ Nationality
УКРАЇНА/UKR

Запис №/ Record No.

Документ №/ Document No.

ПАСПОРТ ГРОМАДЯНИНА УКРАЇНИ Є ВЛАСНІСТЮ УКРАЇНИ

ПЖ «Україна»

Дата видачі/ Date of issue

Орган, що видав/ Authority

04 01 2022

PHOKLP/ RNTRC

Місце народження/ *Place of birth*

М. БОРИСПІЛЬ КИЇВСЬКА ОБЛАСТЬ УКРАЇНА/М.
BORYSPIL KYIVSKA OBLAST UKRAINA/UKR



IDUKR

< <

<<<<<<<<<<<0

PEREDEREI<<BOHDAN<<<<<<<<<<<<<

Комбінований метод стиснення моделей глибинного навчання для пристроїв з обмеженими обчислювальними ресурсами

**Виконав: студент II курсу, групи КМ-41мн
Передерей Богдан Олександрович**

**Науковий керівник:
завідувач кафедри ПМА, канд. техн. наук, доцент
Тавров Данило Юрійович**

Актуальність роботи

1. Перехід обчислень зі сторони сервера до сторони клієнта



- Відсутності потреби явно передавати чутливі дані на сервера для обробки
- Глибша персоналізація моделей завдяки донавчанню
- Зменшення затримок мережі та можливість повної автономності
- Зменшення ціни на хмарні обчислення та інфраструктуру

2. Проблеми із масштабованістю сучасних моделей

- Висока і часто надлишкова параметризація
- Глобальний дефіцит обчислювальних ресурсів
- Обмеженість ПЗ для розгортання на периферійних пристроях

3. Виникає потреба у розробці методів стиснення, що дозволять

- Запускати моделі там, де до цього це було неможливо
- Економити ресурси та масштабуватися



Постановка задачі

Мета дослідження: підвищення рівня стиснення нейронних мереж при зменшенні деградації їхньої точності шляхом інтеграції поширених методів стиснення в єдиний комбінований алгоритм.

Об'єкт дослідження: методи стиснення та перебудови архітектур моделей глибокого навчання у межах парадигми TinyML.

Предмет дослідження: метод комбінованого стиснення моделей архітектури ResNet для класифікації зображень із використанням квантування, підрізання та дистиляції знань; сукупний вплив взаємодії цих технік на точність, інформаційне представлення та обчислювальну складність моделей; підходи поєднання цих методів та їх вплив на баланс між точністю прогнозування та інформаційним представленням моделей з метою досягнення максимального рівня стиснення з мінімальними втратами точності; механізми мінімізації похибок, що виникають при екстремальному стисненні.

Завдання дослідження

- I. Провести аналіз літератури щодо сучасних методів стиснення та алгоритмічної перебудови нейронних мереж для мінімізації ресурсних витрат, особливостей їх застосування та впровадження у процес тренування та розгортання.
- II. Проаналізувати математичні засади розглянутих методів та підходи до їх поєднань.
- III. Розробити ПЗ для експериментального дослідження комбінування методів стиснення нейронних мереж на базі архітектури ResNet.
- IV. Провести серію експериментів для оцінки впливу різних способів поєднання на динаміку між точністю, обчислювальною складністю та інформаційним представленням моделей, емпірично показати нові властивості моделей, що виникли внаслідок стиснення.
- V. Виконати валідацію та верифікацію найкращого запропонованого методу.

Огляд існуючих методів стиснення

- Квантування (перехід до меншої розрядності)
 - За етапом застосування: після навчання (PTQ), у процесі навчання (QAT)
 - За схемою відображення: симетричне, асиметричне
 - За гранулярністю: потензорне, поканальне
 - За об'єктами квантування: ваги, активації, повне
- Підрізання (видалення ваг)
 - За рівнем структурованості: неструктуроване, структуроване
 - За динамікою зміни маски: динамічне, статичне
 - За критеріями значущості ваг: амплітудні (L1-, L2-норми), градієнтні, Гессіанові
- Дистиляція знань (передача вивчених характеристик між моделями)
 - За типом знань: на основі відповідей, ознак, відношень
 - За схемою організації навчання: офлайн, онлайн, самодистиляція

Розвиток комбінування методів стиснення

Назва методу	Суть методу
Deep Compression	Послідовне виконання підрізання, квантування та кодування Хаффмана
CLIP-Q	Паралельне підрізання та квантування у спільному циклі донавчання
QKD	Трьохетапна дистиляція з адаптацією вчителя до квантованого учня для відновлення точності після квантування
PQK	Використання відсіяних під час підрізання ваг як вчителя
QRPK	Зміна розрядності «на льоту» (3–32 біти) без перенавчання завдяки градієнтному масштабуванню
QADS	Поєднання квантування під час навчання із динамічним підрізання з переходом до статичного підрізання

Математичні засади квантування

1. Оператор симетричного квантування: $x_q = \text{clip}\left(\left\lfloor \frac{x}{\Delta} \right\rfloor, q_{min}, q_{max}\right)$

- Діапазон для n-біт $[q_{min}; q_{max}] = [-2^{n-1}; 2^{n-1} - 1]$.
- Крок квантування $\Delta = \frac{\alpha}{2^{n-1}-1}$, де $\alpha = \max(|x|)$ із діапазону початкових значень.

2. Апроксимація градієнтів: при QAT для зворотного проходу застосовують пряму оцінку (STE)
 $\frac{\partial q_{fake}(x)}{\partial x} \approx 1$ у межах динамічного діапазону $[\alpha, \beta]$, інакше 0 (для стабілізації навчання)

3. Модифікація Learned Step Size Quantization (LSQ): крок Δ оптимізується разом із вагами

$$x_q = \text{clip}\left(\left\lfloor \frac{x}{\Delta} \right\rfloor, q_{min}, q_{max}\right) \cdot \Delta.$$

- $\frac{\partial \mathcal{L}}{\partial \Delta}$ обчислюється через STE.
- Ініціалізація $\Delta_{init} = \frac{2\langle |v| \rangle}{\sqrt{q_{max}}}$.
- Масштабування градієнта $g = \frac{1}{\sqrt{N \cdot q_{max}}}$ стабілізує навчання.

Формалізація підрізання

Навчання моделі — мінімізація функції втрат із маскованими параметрами:

$$\min_{W, M} \mathcal{L}(W \odot M; \mathcal{D}), \text{ s.t. } \|M\|_0 \leq \kappa.$$

Критерій значущості:

- L1-норма $s_{i,j} = |w_{i,j}|$
- L2-норма $s_{i,j} = w_{i,j}^2$

Оновлення ваг

- для статичного $w \leftarrow w - M \odot \eta \frac{\partial \mathcal{L}}{\partial w}$,
- для динамічного $w \leftarrow w - \eta \frac{\partial \mathcal{L}}{\partial w}$.

Формалізація дистиляції

Дистиляція знань (на основі відповідей): комбінація дивергенції Кульбака-Лейблера D_{KL} (логіти учня та вчителя) та перехресної ентропії $\mathcal{L}_{CE}$:

$$\mathcal{L}_{\text{total}} = (1 - \alpha)\mathcal{L}_{CE}(y, \sigma(z_s)) + \alpha T^2 D_{KL}(\sigma(z_t/T) \parallel \sigma(z_s/T)),$$

де T — температура, α — ваговий коефіцієнт.

Офлайн-дистиляція: оптимізуються лише параметри учня (θ_s), параметри вчитель (θ_t) фіксовані:

$$\theta_s^* = \arg \min_{\theta_s} \sum_{x \in X} \mathcal{L}_{\text{total}}(f(x, \theta_t); f(x, \theta_s))$$

Опис методу QADS

- ❑ **Базовий рівень:** Quantization-Aware Training With Dynamic and Static Pruning, модифікація QADS-Freeze.
- ❑ **Головна ідея:** синхронне QAT та неструктуроване динамічне підрізання з переходом до статичного
- ❑ **Мета:** стабілізація донавчання та максимізація кінцевої точності.

Процедура навчання алгоритму QADS-Freeze:

Етап 1: Розігрів (Warm-up, 1–10 епохи):

- Тренування повнорозмірної мережі для отримання початкових наближень ваг
- Запобігає деградації навчання від надмірної регуляризації.

Етап 2: QAT + Динамічне підрізання (11–103 епохи).

- QAT-LSQ із оновленням маски кожні 8 ітерацій.
- Зростання розрідженості до 90% за кубічним законом: $s_t = S_{target} - S_{target} \cdot (1 - t/T_{target})^3$.

Етап 3: Статичне підрізання (104–122 епохи).

- Маска накладається на зворотному проході, що
- Усуває конфлікт подвійної апроксимації градієнтів.
- Стабілізація перед зниженням LR.

Етап 4: Фіксація топології (Freeze, 123–162 епохи).

- Синхронне замороження маски та зниження LR.
- Дотренування зафіксованої топології біля точки оптимуму.

Умови експериментів

- ❑ **Мета:** інтегрувати дистиляцію знань у QADS-Freeze, базові налаштування не змінювалися.
- ❑ **Набори даних:** CIFAR-10 (початкова перевірка) та CIFAR-100 (фінальна валідація). Розподіл навчальної / тестової вибірки — 50,000 / 10,000 зображень, задіяна аугментація (Normalization, Crop, Flip).
- ❑ **Модель:** архітектури сімейства ResNet із характеристиками тренування:
 - 162 епохи, розмір батчу 128.
 - Оптимізатор SGD (Momentum = 0,9; L2-регуляризація = 0,0001).
 - Зменшення кроку навчання LR у 10 разів на 80-й та 123-й епохах.
- ❑ **Цільова архітектура учня:** ResNet-32 INT2 із розрідженістю у 90%. Всі стиснуті моделі у експериментах тренувалися методом QADS-Freeze із розрідженістю у 90%.
- ❑ **Дистиляція:** на основі відповідей. Базові гіперпараметри ($T = 3$; $\alpha = 0,5$)
- ❑ **Конфігурації гіперпараметрів:** для CIFAR-100 використовувалася бібліотека Optuna із методами беєсівської оптимізації. Підбір параметрів дистиляції відбувався протягом 30 циклів тренування із діапазонами пошуку $\text{teacher_bits} \in \{\text{INT3}, \text{INT4}, \text{INT6}\}$, $T \in [1,5; 8]$, $\alpha [0,1; 0,9]$.
- ❑ **Апаратна складова:** локальна NVIDIA RTX 3060 та серверні NVIDIA T4.

Результати експериментів

Таблиця 1 – Вплив розрядності квантування вчителя на ефективність дистиляції знань на CIFAR-10

Вчитель	Учень	Точність вчителя	Точність базового рівня	Точність учня із дистиляцією	Різниця вчителя і базового рівня
ResNet32 FP32	ResNet32 INT2	92,95	82,67±0,27	83,55	10,28
ResNet32 INT6	ResNet32 INT2	91,72	82,67±0,27	83,07	9,05
ResNet32 INT4	ResNet32 INT2	91,02	82,67±0,27	<u>83,67</u>	8,35
ResNet32 INT3	ResNet32 INT2	89,32	82,67±0,27	83,23	6,65
ResNet32 FP32	ResNet32 INT4	92,95	91,02±0,09	86,86	1,93
ResNet32 INT2	ResNet14 INT2	82,67	80,22	77,73	2,45

Запуск №	Точність (%) при дистиляції під час всього навчання	Точність (%) при дистиляції після динамічного підрізання
1	83,67	83,55
2	83,41	83,07
3	83,48	83,65
4	83,20	82,92
5	83,67	83,57
Середнє (μ)	83,49	83,35
Відхилення (σ)	0,20	0,33
Приріст	+0,82	+0,68

Таблиця 2 – Результати незалежних запусків методу QADS-Freeze із дистиляцією знань від вчителя ResNet-32 INT4 до учня ResNet-32 INT2 на CIFAR-10

Результати експериментів




Рисунок 1 – Порівняння стабільності метрик методу QADS-Freeze без та із дистиляцією знань, задіяної на різних етапах тренування на CIFAR-10

Результати експериментів

Тип атаки	ResNet32 FP32	Вчитель ResNet32 INT4	ResNet32 INT2	ResNet32 INT2 із дистиляцією під час всього навчання	ResNet32 INT2 із дистиляцією після динамічного підрізання
Без атак	92,95	91,58	82,57	83,63	83,17
FGSM	42,59	57,45	58,19	59,15	57,73
PGD	27,04	37,78	46,23	48,18	46,76
MIFGSM	18,54	24,54	41,34	41,97	43,46
DIFGSM	16,97	24,56	41,02	42,12	42,90
TIFGSM	28,46	34,23	46,73	47,42	45,77

Таблиця 3 – Оцінка стійкості стиснутих моделей до змагальних атак типу білої скриньки на CIFAR-10

Результати експериментів

Вчитель	Учень	Точність вчителя	Точність базового рівня	Точність учня із дистилляцією	Різниця вчителя і базового рівня
ResNet32 FP32	ResNet32 INT2	69,78	45,29±0,38	44,24	24,49
ResNet32 INT6	ResNet32 INT2	67,80	45,29±0,38	44,04	22,51
ResNet32 INT4	ResNet32 INT2	65,40	45,29±0,38	43,57	20,11
ResNet32 INT3	ResNet32 INT2	60,77	45,29±0,38	43,92	15,48
ResNet32 FP32	ResNet32 INT3	69,77	61,38±0,41	10,29	8,39
ResNet32 INT6	ResNet32 INT3	67,80	61,38±0,41	55,61	6,42
ResNet32 INT6	*ResNet32 INT3	67,80	61,38±0,41	60,99	6,42

Таблиця 5 – Незалежні запуски методу QADS-Freeze із дистилляцією знань від вчителя ResNet-32 INT4 до учня ResNet-32 INT2 ($T = 1,621$ та $\alpha = 0,267$) на CIFAR-100.

Таблиця 4 – Вплив розрядності квантування моделі-вчителя на ефективність дистилляції знань на CIFAR-100

Запуск №	Точність (%)
1	46,42
2	46,41
3	46,67
4	45,88
5	46,35
Середнє (μ)	46,35
Відхилення (σ)	0,29
Приріст	+1,06

Рівень стиснення моделей

Модель	Кількість параметрів	Кількість ненульових параметрів	Розмір параметрів (кілобайти)	Розмір ненульових параметрів (кілобайти)
ResNet-32 FP32	465 072	463 840	1816,69	1811,88
ResNet-32 INT6	465 072	50 935	340,63	37,31
ResNet-32 INT4	465 072	50 935	227,09	24,87
ResNet-32 INT3	465 072	50 935	170,31	18,65
ResNet-32 INT2	465 072	50 935	113,54	12,44

Розміри тренувальних параметрів моделей, стиснутих методом QADS-Freeze

Науково-практичні результати

- ❑ **Наукова новизна:** удосконалено метод QADS-Freeze завдяки його поєднанню із дистиляцією знань, що дало змогу компенсувати втрату інформаційної ємності моделі за рахунок передачі прихованих знань протягом усього процесу перебудови архітектури.
- ❑ **Практична цінність:** запропонований метод забезпечує радикальне зменшення обсягу пам'яті для збереження ваг і обчислювальних витрат на виконання моделей за умови меншої деградації точності. Отримані результати можуть бути інтегровані у процеси розробки інтелектуальних систем для периферійних пристроїв у межах парадигми TinyML.
- ❑ **Публікація:** Perederei B. Qureshi F. Single Hyperspectral Image Super-Resolution Utilizing Implicit Neural Representations. Proceedings of the 14th International Conference on Pattern Recognition Applications and Methods — Volume 1: ICPRAM / INSTICC. SciTePress. 2025. P. 628–635.

Висновки

- I. Виконано огляд літератури методів стиснення та їх поєднання. Через недоліки послідовної комбінації обґрунтовано спільне застосування квантування, підрізання, та дистиляції знань.
- II. Розглянуто математичний апарат методів, що заклало теоретичну основу для їх практичної реалізації.
- III. Розроблено програмне забезпечення для проведення експериментального дослідження на базі фреймворку PyTorch без залучення сторонніх високорівневих бібліотек для стиснення.
- IV. Проведено експерименти на CIFAR-10. Показано, що дистиляція логітів від вчителя проміжної розрядності до екстремально стисненого учня протягом усього навчання стабілізує процес тренування. Точність класифікації ResNet-32 INT2 зросла у середньому на 0,82% порівняно із базовим методом QADS-Freeze. Емпірично підтверджено підвищення стійкості моделей до змагальних атак типу білої скриньки з приростом точності до 0,5–2%.
- V. Провалідовано запропоновану комбінацію методів на CIFAR-100. Подолано первинну деградацію точності завдяки беєсівській оптимізації гіперпараметрів. Знайдено нетипову конфігурацію ($T=1,621$ та $\alpha=0,267$), яка ефективно пригнічує фоновий шум від 100 класів та помилки моделі-вчителя. Досягнуто точності моделі ResNet-32 INT2 у 46,35%, що на 1,06% перевищує QADS-Freeze без дистиляції.